

Introducción a Machine Learning con AWS.

Victor Ascencio | 25 de Octubre 2020

Linkedin

vascencio@gmail.com



Es la rama del campo de la inteligencia Artificial, que busca como dotar a las maquinas de capacidad de aprendizaje.

Conocimientos de programación Machine Learning

Matematicas y mi Estadistica

Data Science

Desarrollo de Software

Tradicional

Investigación Tradicional

Experiencia en area a analizar.





¿CÓMO APRENDEN LAS MAQUINAS?





Escenarios donde puedo aplicar ML.

Clasificacion de imagenes Detección de fraude. Retención de clientes. Diagnosticos.

Clasificación

Aprendizaje Supervisado

Predicción del clima. Predicción de ventas. Expectivas de vida. Tendencias de popularidad.

Regresión

Machin

Aprendizaje Retrøalimentado

COMUNIDAD DOJO

Descisiones en Tiempo Real Condución autonoma. Juegos con IA.

Machine Learning

Aprendizaje no supervisado

Clustering

Sistemas de recomendaciones.

Segmentación de clientes. Reducción

OMUNIO

OFENSIVA Y DEFENSIVA

de dimensiones

Visualización de Big Data.

Adquisición de habilidades. Regresión Logística. Árboles de decisión. **Bosques Aleatorios.**

Algoritmos de Machine Learning

Clasificación

Regresión

Aprendizaje Supervisado

Linear Regression. Máquinas de vectores de soporte. Arboles de decisión.

Machine

Aprendizaje Retroalimentado

COMUNIDAD DOJO

COMUNIO

OFENSIVA Y DEFENSIVA

Procesos de Decisión de Markov. Procesamiento del Lenguaje Natural (NLP en inglés).

Learning

Aprendizaje no supervisado

Clustering

Reducción

de dimensiones

Principal Component Analysis (PCA)

Clustering K-Means

Servicios de AWS de Machine Learning.

Amazon Fraud Detector.

Clasificación

Amazon Forecast, analisis de series de tiempo, promociones, precios por ejemplo.

Regresión

Aprendizaje Supervisado



Aprendizaje no supervisado

Clustering

Amazon Personalize Sistema de recomendaciones



Aprendizaje Retroalimentado Amazon
DeepRacer
Entrenamiento
de conducción
de autos con apredizaje
reforzado.

Reducción

de dimensiones

AWS Lake Formation Eliminación de datos duplicados con Machine Learning.

Proceso de despliegue de un Proyecto de Machine Learning



Obtención de datos.

> Limpieza, Preparación y Manipulación de datos.

Entrenamiento del Modelo.

> Prueba de resultados.

Implementación Y

Mejora

COMUNIO COMUNIDAD DOJO OFENSIVA Y DEFENSIVA

Servicios disponibles:

- Data Labeling.
- Model Building.
- **Training**
- Tunning and Deployment.



Creación

Entrene y ajuste

Implemente y administre

Amazon SageMaker Ground Truth

Build and manage training data sets

Amazon SageMaker Studio

Integrated development environment (IDE) for machine learning

Amazon SageMaker Autopilot

Automatically build and train models

Amazon SageMaker Model Monitor

Automatically detect concept drift

Amazon SageMaker Notebooks

One-click notebooks with elastic compute

Amazon SageMaker Experiments

Amazon SageMaker Neo

Capture, organize, and search every step Train once, deploy anywhere

AWS Marketplace

Pre-built algorithms and models

Amazon SageMaker Debugger

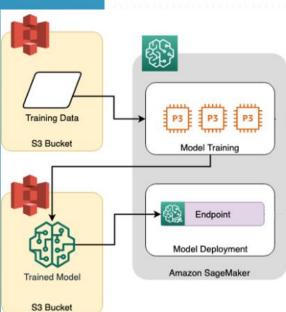
Debug and profile training runs

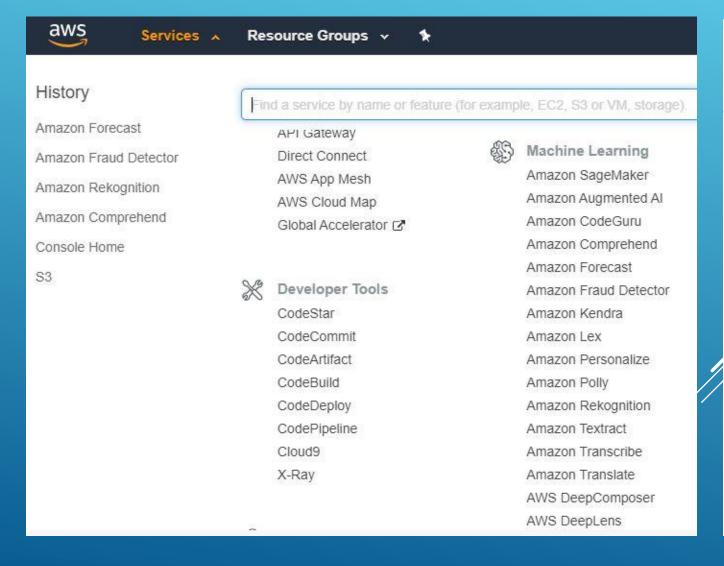
Amazon Augmented Al

Add human review of model predictions

Automatic Model Tuning

One-click hyperparameter optimization







Amazon SageMaker

×

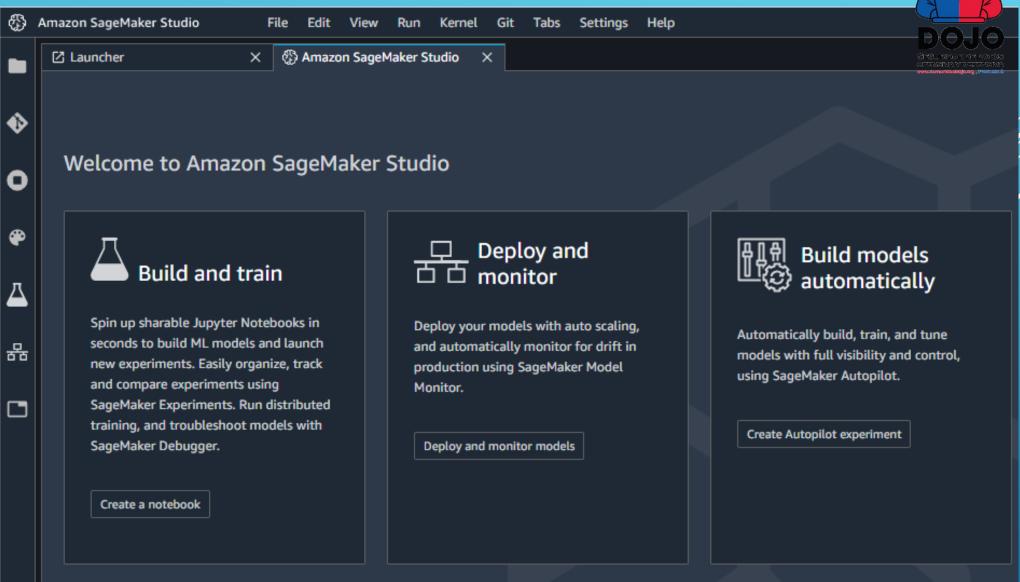
Amazon SageMaker Studio

Dashboard

Search

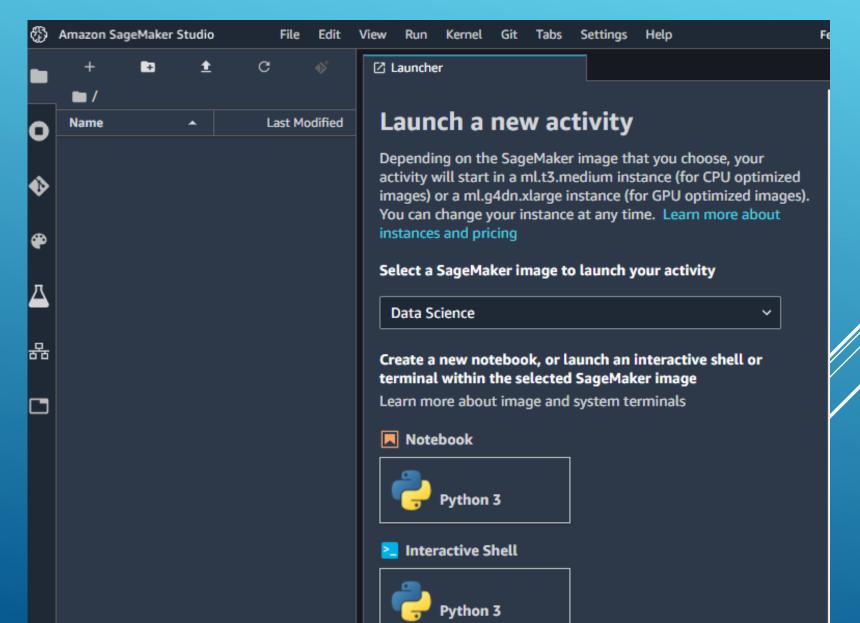
- Ground Truth
- Notebook
- Processing
- Training

Version: 1.24.3





COMUNIO









Importación de las librerías.

```
[61]: #Preparación de datos
    import os
    import pandas as pd
    from sklearn.model_selection import train_test_split
    from sklearn.preprocessing import OrdinalEncoder
    import sagemaker
    # Modelado
    from sklearn.svm import SVC
    from sklearn.tree import DecisionTreeClassifier
    from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
    from sklearn.neighbors import KNeighborsClassifier
    #Prueba Inferencia.
    import boto3
    import pandas as pd
```

Lectura de datos.

DOJO SEGURIDAD DE DATOS OFENSIVA Y DEFENSIVA



Descarga y Lectura del dataset

```
[38]: #%%sh
       Verificamos la ruta de trabajo para los datos.
[39]: pwd
       '/root/sagemaker-studio-demo'
       Hacemos una ispección de los datos.
[119]: DATA PATH
       df = pd.read csv(DATA PATH+'bank-full.csv', sep=';')
                              marital education default balance housing loan
                                                                               contact day month duration campaign pdays previous
[119]:
              age
                                        tertiary
                                                          2143
                                                                                                      261
                  management
                              married
                                                                                                                                    unknown no
                                                            29
                                                                                                      151
                     technician
                                single secondary
                                                    no
                                                                         no unknown
                                                                                                                        -1
                                                                                                                                 0 unknown no
```

Lectura de datos.

```
[65]: df.info()
      <class 'pandas.core.frame.DataFrame'>
      RangeIndex: 45211 entries, 0 to 45210
      Data columns (total 17 columns):
                     Non-Null Count Dtype
          Column
                     45211 non-null int64
          job
                     45211 non-null object
          marital
                    45211 non-null object
          education 45211 non-null object
           default
                     45211 non-null object
          balance
                     45211 non-null int64
          housing
                     45211 non-null object
                     45211 non-null object
          loan
                     45211 non-null object
          contact
                     45211 non-null int64
                     45211 non-null object
          month
       11 duration 45211 non-null int64
       12 campaign 45211 non-null int64
         pdays
                     45211 non-null int64
       14 previous 45211 non-null int64
       15 poutcome 45211 non-null object
       16 y
                     45211 non-null object
      dtypes: int64(7), object(10)
      memory usage: 5.9+ MB
```



Adecuación de los datos.





Separamos el dataset en el grupo de entrenamiento y test

```
[25]: train, test = train_test_split(data, test_size=0.2)

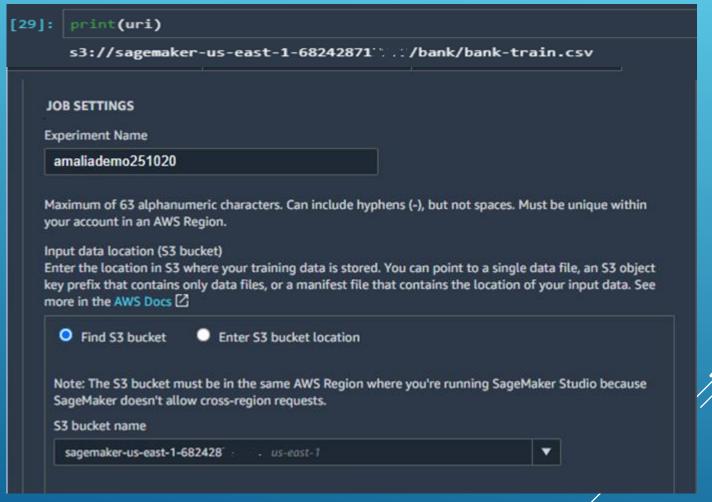
Guardamos los datos en csv para el entrenamiento y validación posterior.

[27]: train_file = DATA_PATH+'bank-train.csv'
    pd.DataFrame.from_records(train).to_csv(train_file, index=False, header=True, sep=',')
    test_file = DATA_PATH+'bank-test.csv'
    pd.DataFrame.from_records(test).to_csv(test_file, index=False, header=True, sep=',')
```

Subimos el dataset para entrenamiento al bucket de S3

```
[30]: session = sagemaker.Session()
uri = session.upload_data(path=train_file, key_prefix='bank')
```

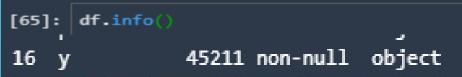
Creamos el experimiento con autopilot.







Creamos el experimiento con autopilot.



For more information on the format of a manifest file, please see the AWS Docs

Target attribute name

The target attribute is the attribute in your dataset that you want Amazon SageMaker Autopilot to make predictions for.

16

The attribute name is case-sensitive and must match exactly the name in your input dataset

Output data location (S3 bucket)

Enter the location in S3 where you want to store the output.

○ Find S3 bucket ○ Enter S3 bucket location

Note: The S3 bucket must be in the same AWS Region where you're running SageMaker Studio because SageMaker doesn't allow cross-region requests.

▼

S3 bucket name

sagemaker-us-east-1-6824287 us-east-1





DOJO
SEGURIDAD DE DATOS
OPENIO Y O DEFENIO Y O DEFENIO



. Seleccionamos el tipo de entrenamiento.

Select the machine learning problem type

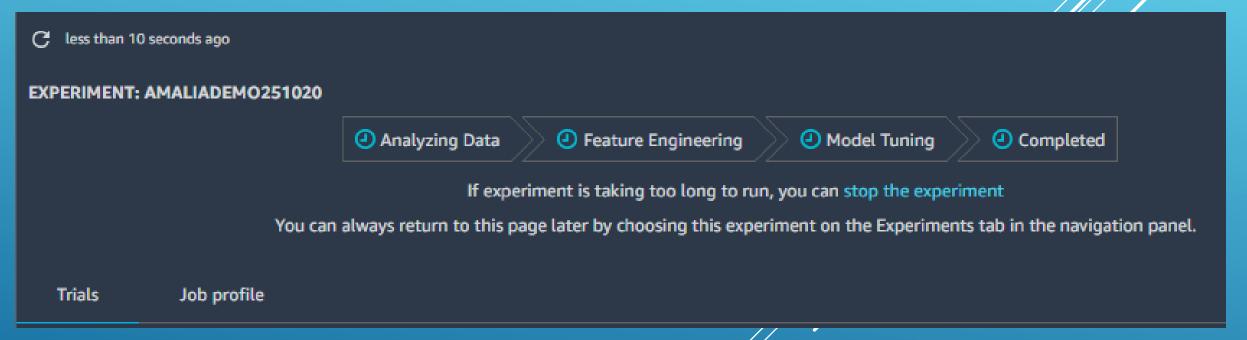
- Auto
- Binary classification
- Regression
- Multiclass classification

Do you want to run a complete experiment?

- Yes
- No, run a pilot to create a notebook with candidate definitions

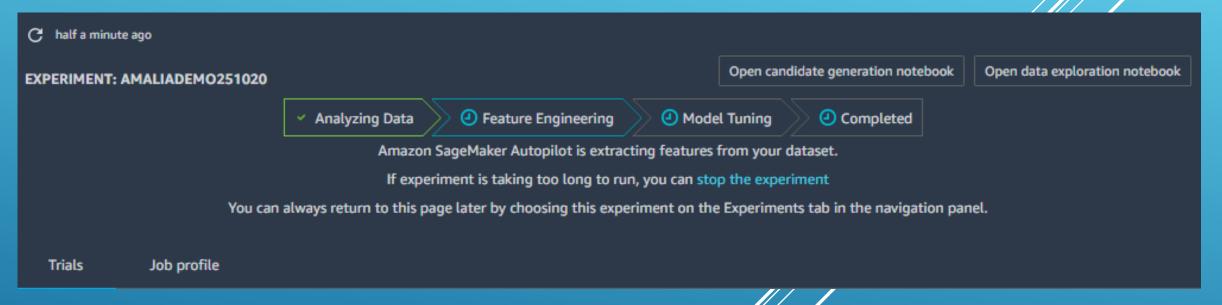


. Esperamos a que se autoejecuten las etapas del entrenamiento.





Esperamos a que se autoejecuten las etapas del entrenamiento.



Notebook generado.

Open data exploration notebook



- Understand how the job analyzed features to select the candidate pipelines.
- Modify and improve the generated AutoML pipelines using knowledge that you have about the dataset.

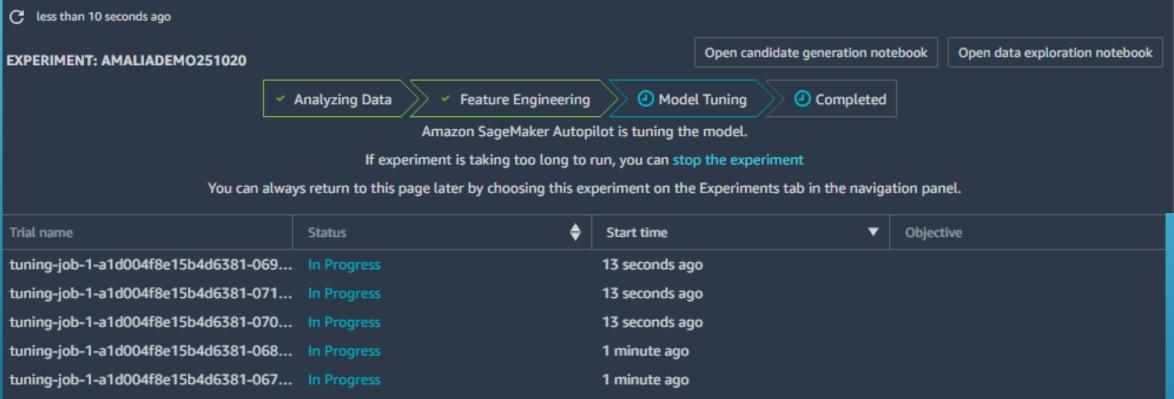
We read 36168 rows from the training dataset. The dataset has 17 columns and the column named 16 is used as the target column. This is identified as a BinaryClassification problem. Here are 2 examples of labels: ['1.0', '0.0'].

Suggested Action Items

Verify the number of unique values of a feature is expected with respect to domain knowledge. If it differs, one explanation could be multiple encodings of a value. For example US and U.S. will count as two different words. You could correct the error at the data source or pre-process your dataset in your S3 bucket.

Esperamos a que se autoejecuten las etapas del entrenamiento.





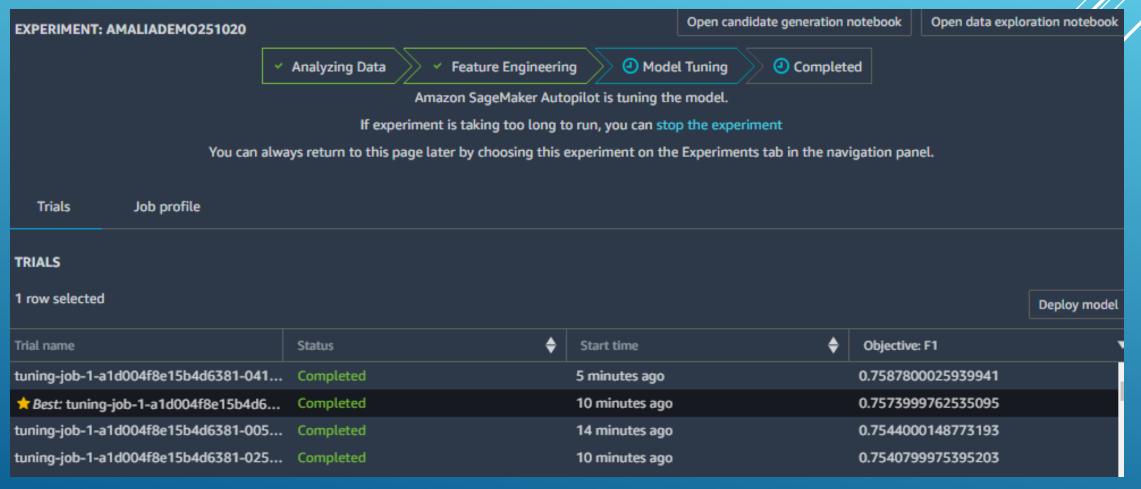
DOJO
SEQURIDAD DE DATOS
OPENSIONA
POW COMUNIDAD DOJO

MARCHITECTURE

SEQUENCIANO

S

. Análisis de modelo.



Notebook open candidate.



The AutoML recommendation job has recommended the following hyperparameters, objectives and accuracy metrics for the algorithm and problem type:

```
ALGORITHM OBJECTIVE METRICS = {
    'xgboost': 'validation:f1',
    'linear-learner': 'validation:binary f beta',
STATIC_HYPERPARAMETERS = {
    'xgboost': {
        'objective': 'binary:logistic',
        'save model on termination': 'true',
        'scale pos weight': 7.524157435776573,
    'linear-learner': {
        'predictor type': 'binary classifier',
        'loss': 'logistic',
        'mini batch size': 800,
        'binary classifier model selection criteria': 'loss function',
        'num models': 1,
        'positive example weight mult': 7.524157435776573,
    },
```

Notebook open candidate.

```
[ ]: from sagemaker.parameter import CategoricalParameter, ContinuousParameter, IntegerParameter
     ALGORITHM TUNABLE HYPERPARAMETER RANGES = {
         'xgboost': {
              'num round': IntegerParameter(2, 1024, scaling type='Logarithmic'),
              'max depth': IntegerParameter(2, 8, scaling type='Logarithmic'),
              'eta': ContinuousParameter(1e-3, 1.0, scaling type='Logarithmic'),
              'gamma': ContinuousParameter(1e-6, 64.0, scaling type='Logarithmic'),
             'min child weight': ContinuousParameter(1e-6, 32.0, scaling type='Logarithmic'),
              'subsample': ContinuousParameter(0.5, 1.0, scaling type='Linear'),
              'colsample bytree': ContinuousParameter(0.3, 1.0, scaling type='Linear'),
              'lambda': ContinuousParameter(1e-6, 2.0, scaling type='Logarithmic'),
             'alpha': ContinuousParameter(1e-6, 2.0, scaling type='Logarithmic'),
         'linear-learner': {
             'wd': ContinuousParameter(1e-7, 1.0, scaling type='Logarithmic'),
              'll': ContinuousParameter(1e-7, 1.0, scaling type='Logarithmic'),
              'learning rate': ContinuousParameter(1e-5, 1.0, scaling type='Logarithmic'),
         },
```

OMUNIO

COMUNIDAD DOJ

Notebook open candidate.



Finally, deploy the model to SageMaker to make it functional.

Congratulations! Now you could visit the sagemaker endpoint console page to find the deployed endpoint (it'll take a few minutes to be in service).

DOJO
SEGURIDAD DE DATOS
OPENSIVADA
WWw.comunicaddojc.gag. PANAMA



. Hacemos el despliegue de end point.

Deploy model

REQUIRED SETTINGS

Endpoint name

Sagemaker07082020

Maximum of 63 alphanumeric characters. Can include hyphens (-), but not spaces. Must be unique within your account in an AWS Region.

Instance type

Instance count

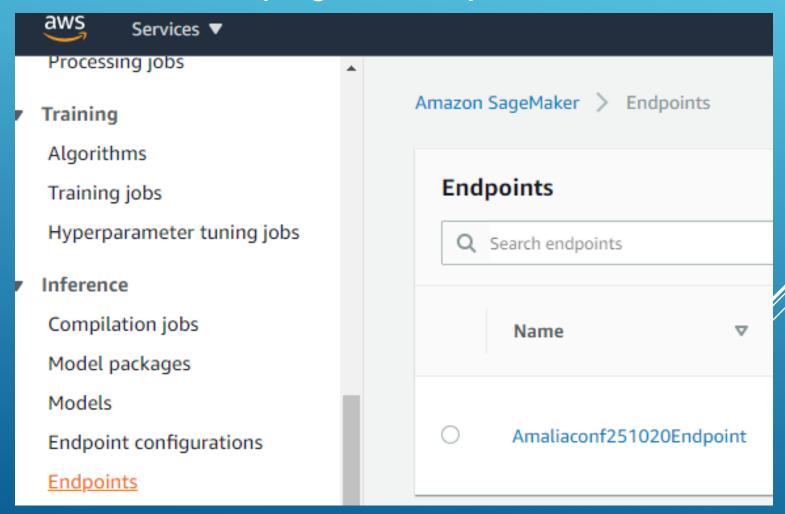
ml.m5.xlarge

<u></u>

Data capture

SageMaker Studio will save prediction requests and responses from the endpoint to an Amazon S3 location specified below

Verificamos el despliegue del endpoint.





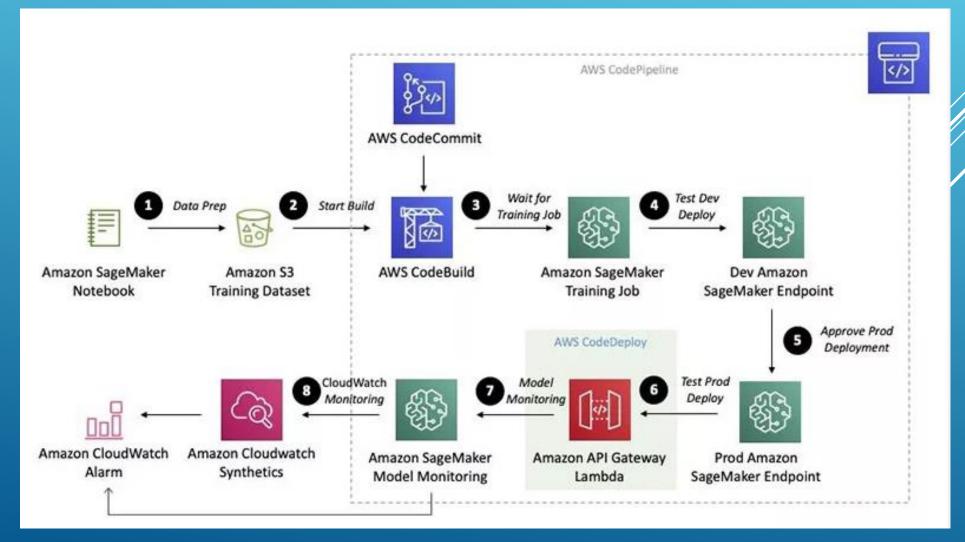
Hacemos la prueba de inferencia.



```
Prueba de Inferencia.
[13]: sm = boto3.Session().client('runtime.sagemaker')
[14]: def infer(endpoint, input_data):
          response = sm.invoke_endpoint(EndpointName=endpoint, ContentType='text/csv', Accept='text/csv', Body=input_data)
          prediction = response['Body'].read().decode("utf-8")
          return prediction
[19]: endpoint = 'Amaliaconf251020Endpoint'
      data = '17.0,1.0,1.0,1.0,0.0,916.0,1.0,0.0,0.0,8.0,5.0,279.0,0.0,0.0,0.0,0.0,3.0
      prediction = infer(endpoint, data)
      print(prediction[0])
      0
[20]: if prediction[0] == '0':
          print('No se recomienda ofertarle el servicio')
      No se recomienda ofertarle el servicio
```

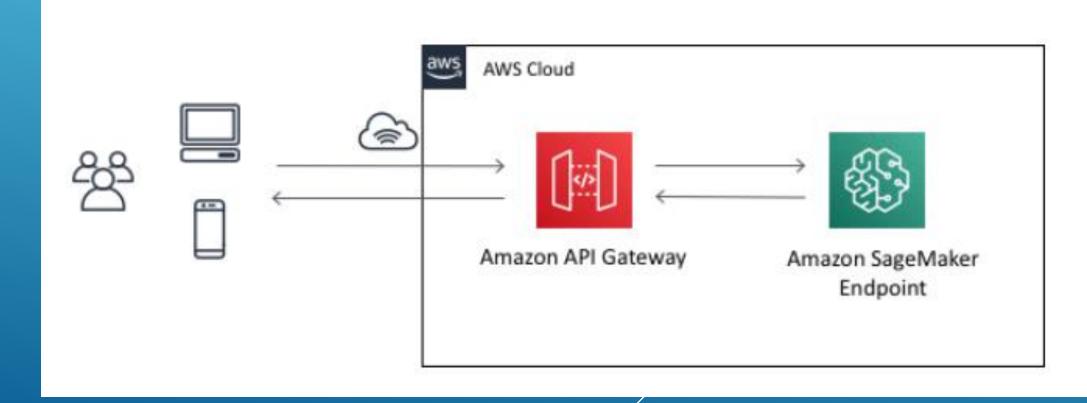
DOJO
SEGURIDAD DE DATOS
OPERINANO
MACCIONADO
SEGURIDAD DE DATOS
OPERINANO
SEGURIDAD DE SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDAD
SEGURIDAD
SEGURIDAD DE SEGURIDAD
SEGURIDA

Siguiente paso el monitoreo del endpoint.





Como ultimo paso es interactuar con el endpoint y nuestras aplicaciones.



. Documentación

Ejemplos AWS Sagemaker

https://aws.amazon.com/es/sagemaker/getting-started/

https://github.com/vascencio/amaliaconf





GRACIAS.

Victor Ascencio | 25 de Octubre 2020

Linkedin

vascencio@gmail.com